第一部分 高等概率论基础性能测点

col1	col2	col3

一、事件与集合

1.1 Def 全样本空间、底层状态、事件、发生

称全集 Ω 为$全样本空间$（sample space），其中每个元素 $\omega \in \Omega$ 表示每一种底层状态

每个集合 Ω 中的子集为一个事件，一个事件 A 发生 Ω

第 1 章 随机变量、测度与期望

> **本章对应原笔记《随机微积分 (1)：随机变量；测度、分布；期望积分的回顾》。**
> 对照 Øksendal：第 2 章 §2.1 （Probability Spaces, Random Variables and Stochastic Processes）、附录 A （正态随机变量）、附录 B （条件期望的严格构造，对应本书第 2 章）。

这一章解决什么卡点

大多数人学概率论时，"随机变量"就是"一个随机变化的数"，拿到这个图像就能算题。但到了随机微积分和金融定价，这个图像会悄悄坑你两次：

第一次是在**测度变换**（第 11–12 章）——同一支股票、同一批可能的世界状态，把概率重新分配一下，"随机行为"就全变了。这时你必须分清楚：变的是什么？没变的是什么？答案藏在"随机变量 = 样本空间上的可测函数"这个更深的图像里。

第二次是在**信息**（第 2–3 章）——定价的本质是"在部分信息下做最优预测"。要谈"部分信息"，就得先把"信息"本身数学化，而这个数学化用的材料——σ-代数——正是可测性定义的原材料。

所以本章把初等概率论的地基重砌一遍：可测空间、可测函数、诱导测度、勒贝格积分。每一步都不难，但每一步都是为了后面某处的"哦，原来那时候是在用这个"

1.1 随机变量

1.1.1 Def 底层样本空间

(1) 设 Ω 为**底层样本空间（underlying sample space）**：其中每一个元素 $\omega \in \Omega$ 表示每一种可能发生的底层状态。

(2) 设 Ω 上有 σ-代数 $\mathcal{F}$，则定义 $(\Omega, \mathcal{F})$ 为**底层可测空间**：$\mathcal{F}$ 表示所有可能将会得知的信息集合，$\mathcal{F}$ 的每一个元素子集 $E \in \mathcal{F}$ 称为**事件**；事件通过可列并、补运算得到的集合 $F \in \mathcal{F}$，即仍为事件。

严格定义：$\mathcal{F}$ 为由"基本事件"通过某些集合运算建立的满足一定性质的集族（对可列并、补运算封闭，且 $\Omega \in \mathcal{F}$）。其中的元素为可测集 $E \in \mathcal{F}$。

> **严格性注记（省略了什么）**：σ-代数的存在性与"生成"运算（由任意集族 $\mathcal{E}$ 生成最小 σ-代数 $\sigma(\mathcal{E})$，即所有包含 $\mathcal{E}$ 的 σ-代数之交）这里当作已知；测度的构造（Carathéodory 扩张定理）在第 3 章需要时会现场补一笔。系统补课可看任何一本实变函数教材，本书不展开——我们要尽快到达有意思的地方。

理解：为什么"信息"要用 σ-代数装？因为如果你能判断事件 E 发生与否、也能判断 F 发生与否，那你自动就能判断 E^c（"没发生"）和 $E \cup F$（"至少一个发生"）——可数的并和补是"信息"封闭运算的自然边界（可数交由 De Morgan 律白送）。
所以一个 σ-代数恰好是"一套自洽的、可以整体得知的问答集"。

1.1.2 Def 观测样本可测空间

$(\mathbb{R}^k, \mathcal{B}(\mathbb{R}^k))$ 其中 $\mathcal{B}(\mathbb{R}^k)$ 为 $\mathbb{R}^k$ 上的 **Borel σ-代数**（由所有 k 维开矩体生成的最小 σ-代数），称为**观测样本可测空间**。

理解：数值观测的落点空间。我们最终关心的量（价格、利率、波动率）都活在这里；Borel 结构保证了"开矩体"这类最朴素的观测问题（"价格落在 100 到 101 之间吗"）都是合法事件。

1.1.3 Thm-Def X 的诱导 σ-代数

设 $X : (\Omega, \mathcal{F}) \to (\mathbb{R}^k, \mathcal{B}(\mathbb{R}^k))$。记

$$\sigma(X) := \{X^{-1}(B) \,\big|\, B \in \mathcal{B}(\mathbb{R}^k)\}$$

则 $\sigma(X)$ 是 Ω 上的 σ-代数（注意 $X^{-1}(B) \in \mathcal{F}$ 要求 X 可测，见下），称为 X **诱导的 σ-域（σ-field induced by random vector X）**。

证：完全由集合与函数逆像的性质可得。由于 $\mathcal{B}(\mathbb{R}^k)$ 为 σ-域：

(1) $E \in \sigma(X) \Leftrightarrow \exists B \in \mathcal{B},\ s.t.\ E = X^{-1}(B) \overset{B^c \in \mathcal{B}}{\Longrightarrow} E^c = X^{-1}(B^c) \in \sigma(X)$;

(2)$\{E_n\}^{\infty} \subset \sigma(X) \Leftrightarrow \exists \{B_n\}^{\infty} \subset \mathcal{B},\ s.t.\ E_n = X^{-1}(B_n) \overset{\cup_n B_n \in \mathcal{B}}{\Longrightarrow} \bigcup_n^{\infty} E_n = X^{-1}\left(\bigcup_n^{\infty} B_n\right) \in \sigma(X)$。

（另需 $\Omega = X^{-1}(\mathbb{R}^k) \in \sigma(X)$，显然。）

理解：$X : \Omega \to \mathbb{R}^k$ 是对底层样本空间在数值上的**映射汇总**（numerical mapping summary of the
underlying sample space），而汇总一般仅保留部分信息（除非一一对应）。$\sigma(X)$ 已经是**通过 X 能回溯的最多的信息**：只看 X 的取值，你能分辨的世界，最细就细到 X 的原像，再细就分不出了。

1.1.4 Def $\mathcal{F}$-可测随机向量

$X : \Omega \to \mathbb{R}^k$ 为 $(\Omega, \mathcal{F})$ 上的**随机变量（random variable / random vector）** $\Leftrightarrow^{def}$ X 为 $(\Omega, \mathcal{F})$ 上的 $\mathcal{F}$-可测函数，即

$$\forall B \in \mathcal{B}(\mathbb{R}^k), \quad X^{-1}(B) \in \mathcal{F}$$

或等价地 $\sigma(X) \subset \mathcal{F}$：$\sigma(X)$ 为 $\mathcal{F}$ 的子 σ-代数。

理解：可测性意味着**随机变量取值已知**——$\mathcal{F}$ 中包含的事件足以遍历 X 的所有取值问题。不可测时，说明可知信息 $\mathcal{F}$ 无法消除 X 的随机性，只能提供部分条件信息（这正是第 2 章条件期望的出发点）。此外，可测性保证了后续可通过在 $\mathcal{F}$ 上定义概率测度来对 X 定义概率分布。

1.2 概率测度、诱导概率测度与概率分布

1.2.1 Def 概率测度 $\mathbb{P}$

在可测空间 $(\Omega, \mathcal{F})$ 上定义测度 $\mathbb{P}$ 使得 $\mathbb{P}(\Omega) = 1$（且 $\mathbb{P}(E) \geq 0$、可列可加），则称 $\mathbb{P}$ 为**概率测度（probability measure）**，$(\Omega, \mathcal{F}, \mathbb{P})$ 称为**概率空间（probability space）**。

1.2.2 Thm-Def X 诱导概率测度 $\mathbb{P}_X$

设 $(\Omega, \mathcal{F}, \mathbb{P})$ 上随机变量 $X : (\Omega, \mathcal{F}) \to (\mathbb{R}^k, \mathcal{B})$。则一定可在 $(\mathbb{R}^k, \mathcal{B})$ 上定义概率测度 $\mathbb{P}_X$：

$$\forall B \in \mathcal{B}, \qquad \mathbb{P}_X(B) := \mathbb{P}\left(X^{-1}(B)\right)$$

称 $\mathbb{P}_X$ 为 "$\mathbb{P}$ 经 X 诱导到 $(\mathbb{R}^k, \mathcal{B})$ 上的概率测度"。

证（完全由逆像性质使得测度性质被继承）：

(1) 集函数 $\mathbb{P}_X$ 显然继承 $\mathbb{P}$ 的非负性。

(2) 可列可加性：$\forall$ 两两无交的集列 $\{B_n\}^{\infty} \subset \mathcal{B}$，

$$\mathbb{P}_X\Big(\bigcup^{\infty} B_n\Big) = \mathbb{P}\Big(X^{-1}\big(\bigcup^{\infty} B_n\big)\Big) = \mathbb{P}\Big(\bigcup^{\infty}\big(X^{-1}(B_n)\big)\Big) \overset{\mathbb{P}\text{的可列可加}}{=} \sum^{\infty}\mathbb{P}\big(X^{-1}(B_n)\big) = \sum^{\infty}\mathbb{P}_X(B_n).$$

(3) 归一性：$X^{-1}(\mathbb{R}^k) = \Omega$（因 $\mathbb{R}^k \supset X(\Omega) \Rightarrow X^{-1}(\mathbb{R}^k) \supset X^{-1}(X(\Omega)) \supset \Omega$，而反包含显然），故 $\mathbb{P}_X(\mathbb{R}^k) = \mathbb{P}(\Omega) = 1$。

（原笔记此步写作"显然 $X^{-1}(\mathbb{R}^k) \subset \Omega$"再证反包含，两个方向的论证本书合并如上。）

1.2.3 Prop 对随机变量分布的三层理解

设定义在 $(\Omega, \mathcal{F}, \mathbb{P})$ 上的随机变量 X。考察定义在 $(\mathbb{R}^k, \mathcal{B}(\mathbb{R}^k), \mathbb{P}_X)$ 上的随机变量 $g(x) := x$，$g: \mathbb{R}^k \to \mathbb{R}^k$。由于 $\forall B \in \mathcal{B}(\mathbb{R}^k)$，$g^{-1}(B) = B$，且 $\mathbb{P}_X(g^{-1}(B)) = \mathbb{P}_X(B) = \mathbb{P}(X^{-1}(B))$，则两个随机变量 g 与 X 在实数取值空间上的随机行为一致。

由于实空间 Borel 代数上的概率测度等价于在实空间上定义累积分布函数：$\mathcal{B} \equiv \sigma(\{(-\infty, x) \,|\, \forall x \in \mathbb{R}\})$，则

$$F_X(x) := \mathbb{P}_X\big((-\infty, x]\big)$$

可以完全描述测度 $\mathbb{P}_X$。换句话说，诱导概率测度 $\mathbb{P}_X$ 与累积分布函数（CDF）F_X 一一对应。因此在大部分情况下，我们将随机变量直接定义在结果空间上：
$(\Omega' := \mathbb{R}^k,\ \mathcal{F}' := \mathcal{B}(\mathbb{R}^k),\ \mathbb{P}_X)$。由于实空间 Borel 代数上的概率测度等价于在实空间上定义累积分布函数：$\mathcal{B} \equiv \sigma(\{(-\infty, x] \,|\, x \in \mathbb{R}\})$，则

至此，对随机变量的理解有三层：

1. **Simplest**：一个随机变化的数——"看山是山"；
2. **Middle**：一个定义在底层样本空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 上的可测函数——"看山不是山"；
3. **Final**：一个定义在观测样本空间 $(\mathbb{R}, \mathcal{B}, \mathbb{P}_X)$ 上的恒等随机变量——"看山还是山"。

1.2.4 Remark 随机机制、随机变量的作用

(1) 随机机制与概率测度：我们只能通过确定性来模拟不确定性：可测空间 $(\Omega, \mathcal{F})$ 作为底层样本空间，包含 ex-post 所有可明确是否发生了的事件；再通过在 $(\Omega, \mathcal{F})$ 上建立概率测度 $\mathbb{P}$，将 $\mathcal{F}$ 所能表示的各事件映射到发生的可能性大小，从而构建定量的随机机制 $(\Omega, \mathcal{F}, \mathbb{P})$。

(2) 诱导概率测度的作用：底层概率测度 $\mathbb{P}$ 或隐藏、或为主观赋予的先验信息，而现实观测中只能通过 X 的取值行为——即观测诱导概率测度空间 $(\mathbb{R}^k, \mathcal{B}, \mathbb{P}_X)$——来间接分析：$\mathbb{P} \overset{X}{\leftrightarrow} \mathbb{P}_X$。

(3) 诱导概率测度 $\mathbb{P}_X$ 由两个要素决定：一是底层测度 $\mathbb{P}$，二是随机变量 X 对底层样本的赋值规则。随后章节我们会分析：对同一 X，不同 $\mathbb{P}$ 会被诱导成不同的观测空间测度——**测度变换**（第 11 章）。

1.3 勒贝格积分（Lebesgue Integral）

勒贝格积分的起源：

(1) 为了在一般抽象空间 $(\Omega, \mathcal{F})$ 上建立"体积"（测度），进而对定义在该空间上的函数 f 进行积分，只能通过对 f 的**值域**切分：寻找函数值对应的原像 $X^{-1}(B)$ 的测度，再作乘积求和。

(2) 黎曼（Riemann）可积性要求被积函数（integrand）满足"过高"的连续性，因而需要将 integrand 扩充到更广泛的函数类——比如随机过程中大量出现的、只在可测意义上良好的函数。

1.3.1 Def 简单函数（simple function）

设 $(\Omega, \mathcal{F})$ 上的一个 partition $\mathcal{P} := \{A_1, \dots, A_n\} \subset \mathcal{F}$（$A_i$ 两两不交且并起来是 Ω）。设 $B := \{b_1, \dots, b_n\}$，B 中各项为互不相同的实数。则

$$f(\omega) := \sum_{i=1}^{n} b_i \mathbf{1}_{A_i}(\omega)$$

称为 $(\Omega, \sigma(\mathcal{P}))$ 上的**简单函数**。

1.3.2 Lemma 逐点收敛（point-wise convergence）

若 f 为 $(\Omega, \mathcal{F})$ 上非负可测函数 $\Rightarrow$ 存在一列由非负简单函数构成的函数列 $\{f_n\}_{n=1}^{\infty}$，$s.t.\ \forall \omega \in \Omega,\ \lim_{n\to\infty} f_n(\omega) = f(\omega)$。

（标准构造：$f_n(\omega) = \sum_{k=0}^{n2^n-1} \frac{k}{2^n} \mathbf{1}_{\{\frac{k}{2^n} \le f < \frac{k+1}{2^n}\}}(\omega) + n\,\mathbf{1}_{\{f \ge n\}}(\omega)$，它对每个 ω 单调不减地爬向 $f(\omega)$。记住这个"网眼逐层加密"的构造，第 7、8 章构造伊藤积分时用的简单过程逼近是同一个思路。）

1.3.2+ 注 逐点收敛的含义、构造与它为何是地基

(1) 字面含义：逐点收敛是指**固定一个 ω 不动**，看数列 $f_1(\omega), f_2(\omega), \dots$ 是否收敛到 $f(\omega)$：

$$\forall \omega \in \Omega,\ \forall \varepsilon > 0,\ \exists N = N(\omega, \varepsilon),\ s.t.\ n > N \Rightarrow |f_n(\omega) - f(\omega)| < \varepsilon.$$

注意 N **依赖** ω：同一个精度 ε，在 ω_1 处可能第 10 项就达标，在 ω_2 处要等到第 10000 项。作为对比，**一致收敛（uniform convergence）**要求

$$\forall \varepsilon > 0,\ \exists N = N(\varepsilon),\ \forall \omega \in \Omega,\ n > N \Rightarrow |f_n(\omega) - f(\omega)| < \varepsilon,$$

即"所有点同时达标"。一致收敛 $\Rightarrow$ 逐点收敛，反之不成立。本书只要逐点（及后文的几乎必然、L^2），因为一致收敛太奢侈——伊藤积分里的简单过程逼近根本做不到一致，而勒贝格理论的魅力恰在于把收敛要求压到最低，再靠单调性或控制函数把极限搬进积分号。

(2) 它在文中的位置：本节顺序是 1.3.1 简单函数 $\to$ 1.3.2 逐点收敛引理 $\to$ 1.3.3 勒贝格积分。这个顺序不是随意的：1.3.3 的正式定义 $\int f\,d\mu := \sup\{f_s \le f \text{ 的简单函数积分}\}$ 正确但不好用——既算不出具体值，也无法直接证明收敛定理。真正干活的是另一条路：造一列简单函数 $\{f_n\}$ 逼近 f，然后取 $\int f\,d\mu = \lim_n \int f_n\,d\mu$。**1.3.2 正是保证这列简单函数一定存在**；没有它，1.3.3 就是一座没有楼梯的塔。

(3) 构造公式在做什么：拆成三件事。

- **值域切分（横切，不是竖切）**：把值域 $[0, n)$ 以步长 $1/2^n$ 切成 $n2^n$ 个横条，f 落在第 k 条中的 ω 组成集合 $\{\frac{k}{2^n} \le f < \frac{k+1}{2^n}\}$，令其取**左端点值** $\frac{k}{2^n}$。该集合因 f 可测而属于 $\mathcal{F}$，故是合法简单函数；又因取左端点而恒有 $f_n \le f$（在 f 线下）。这正对应 1.3.5 所说的 Lebesgue **横切**："按函数值分堆称重"。
- **高处截断**：$f \ge n$ 的部分用常数 n 顶上——简单函数必须取有限个值，而 f 可能无界；这个"天花板"随 $n \to \infty$ 升到无穷，不损失极限。
- **网格加密**：n 增大时步长 $1/2^n \to 0$、截断阈值 $n \to \infty$，两者共同保证 $0 \le f_n(\omega) \nearrow f(\omega)$（单调不减地爬向 f）。对任意固定 ω，误差不超过当前网格宽度，故 $f_n(\omega) \to f(\omega)$——**这就是逐点收敛。**

直观：像给一张照片逐级提高分辨率，每个像素点 ω 的颜色值越来越接近真值；但各像素达标所需"级数"可以不同，故是"逐点"而非"一致"。

例：取 $\Omega = [0,1]$、$f(\omega) = \omega$。$n = 1$ 时 f_1 在 $[0, 0.5)$ 上取 0、在 $[0.5, 1)$ 上取 0.5；$n = 2$ 时步长变 $1/4$，f_2 在四个等分区间上分别取 $0, 0.25, 0.5, 0.75$。
阶梯函数从下方一层层贴合对角线，网格越来越细，每个点最终被"压"到对角线上。

(4) 为什么"逐点"这个弱条件够用——控制收敛定理在等它：紧接的 1.3.4 的假设正是①逐点收敛（1.3.2 提供）与②存在可积控制函数 g，两者合起来才能把极限搬进积分号。**为什么必须补控制函数？** 光有逐点收敛会翻车：取 $\Omega = (0,1)$、$f_n = n\mathbf{1}_{(0,1/n)}$，则 $\forall \omega > 0$，只要 $n > 1/\omega$ 就有 $f_n(\omega) = 0$，故 $f_n \to 0$ 逐点；但 $\int f_n\,d\mu = n \cdot \frac{1}{n} = 1$ 恒为 1。于是

$$1 = \lim_{n\to\infty} \int f_n\,d\mu \neq \int \Big(\lim_{n\to\infty} f_n\Big) d\mu = 0,$$

"极限和积分闹了分家"。病根在于这列函数没有可积控制函数：质量被挤进一个越来越窄、越来越高的尖峰里跑掉了。（该反例因不单调而排除了单调收敛定理；若 $\{f_n\}$ 单调不减，则"单调性"与"控制函数"

是两条互补的通行证，勒贝格理论中几乎所有换序都靠这两张牌。）

(5) 往后看：同一套"网格加密 + 逼近"的思路在第 7、8 章会以简单**过程**逼近的形式重现，用来定义 $\int H\,dW$：

这里（第 1 章）	后面
用简单**函数**逼近一般可测函数	用简单**过程**（阶梯过程）逼近一般可积过程，定义伊藤积分
逐点收敛	几乎必然收敛 /L^2 收敛（零测集上的坏点无所谓，要求放宽）
$\int f = \lim \int f_n$	伊藤积分作为逼近和的极限存在且唯一

此外第 2 章条件期望的存在性依赖 Radon–Nikodym 定理，而该定理的证明工具正是单调收敛/控制收敛——所以 1.3.2 这个看似不起眼的引理，是全书后面一系列"取极限穿过积分号"操作的第一块地基。

1.3.3 Def 勒贝格积分

(1) 简单函数的勒贝格积分：设 $f_s(\omega) := \sum_{i=1}^{n} b_i \mathbf{1}_{A_i}(\omega)$，则

$$\int f_s \, d\mu := \sum_{i=1}^{n} b_i \, \mu(A_i).$$

（原笔记此处写作 $\sum b_i \mu\{\mathbf{1}_{A_i}^{-1}(b_i)\}$，是同一意思的绕远写法；直接以 $\mu(A_i)$ 计。）

(2) 一般非负可测函数的勒贝格积分：

$$\int f \, d\mu := \sup_{f_s \le f} \left\{ \int f_s \, d\mu \;\middle|\; f_s \text{ 为简单函数}, \forall \omega,\ f_s(\omega) \le f(\omega) \right\}$$

即对 f 线下所有简单函数的积分取上确界（f_s 取遍 f 线下的简单函数）。对一般可测函数 $f = f^+ - f^-$（正部减负部），若 $\int |f| d\mu < \infty$ 则称 f 可积，且 $\int f\,d\mu := \int f^+ d\mu - \int f^- d\mu$。

（原笔记此定义的第一表达式排版残缺、漏掉了 $\mu(A_i)$ 权重与求和结构，本书径直给出正确形态。）

1.3.4 Thm 勒贝格控制收敛（Lebesgue dominated convergence）

设 $f, \{f_n\}_{n=1}^{\infty}$ 均在 $(\Omega, \mathcal{F})$ 上可测，且 $\forall \omega \in \Omega$, $\lim_{n\to\infty} f_n(\omega) = f(\omega)$。若 $\exists$ 非负可积函数 g，且 $\forall \omega \in \Omega$, $\forall n \in \mathbb{N}$, $|f_n(\omega)| \le |g(\omega)|$，则

$$\lim_{n\to\infty} \int f_n \, d\mu = \int \left(\lim_{n\to\infty} f_n \right) d\mu = \int f \, d\mu.$$

（这条定理在本书后面的使用频率高得惊人：第 7、8 章每一步"取极限穿过积分号"都是它；终章交换期望与积分时也要它站台。**没有控制函数 g，极限和积分就会闹分家**——这是勒贝格理论和逐点收敛之间唯一的契约。）

1.3.5 Prop Riemann 与 Lebesgue 积分的异同

(1) 区别：

Riemann–Darboux 方法——先划分**定义域**为 $\{\Delta x_i\}$，再取 $\Delta x_i \to dx$。
过程中利用（针对连续函数的）中值定理取中间函数值 $f^* \in [f^{\inf}, f^{\sup}]$，
上、下达布和双向夹逼收敛

$$\sum_i f_i^{\inf} \cdot \Delta x_i \;\to\; \int f dx \;\leftarrow\; \sum_i f_i^{\sup} \cdot \Delta x_i.$$

Lebesgue 方法——先在**值域**上取一组点 $\{f_k\}$，生成定义域 Ω 的 partition（每个元素可以不连通）：$\{\omega \mid f_{k-1} \le f(\omega) < f_k\}_k$，得到简单函数的线下面积 $\sum_k f_k \cdot \mu(f_{k-1} \le f < f_k)$。不断增加分点、让网眼加密，$\sum_k f_k \cdot \mu(f_{k-1} \le f < f_k) \to \int f(\omega)\, \mu(d\omega)$。

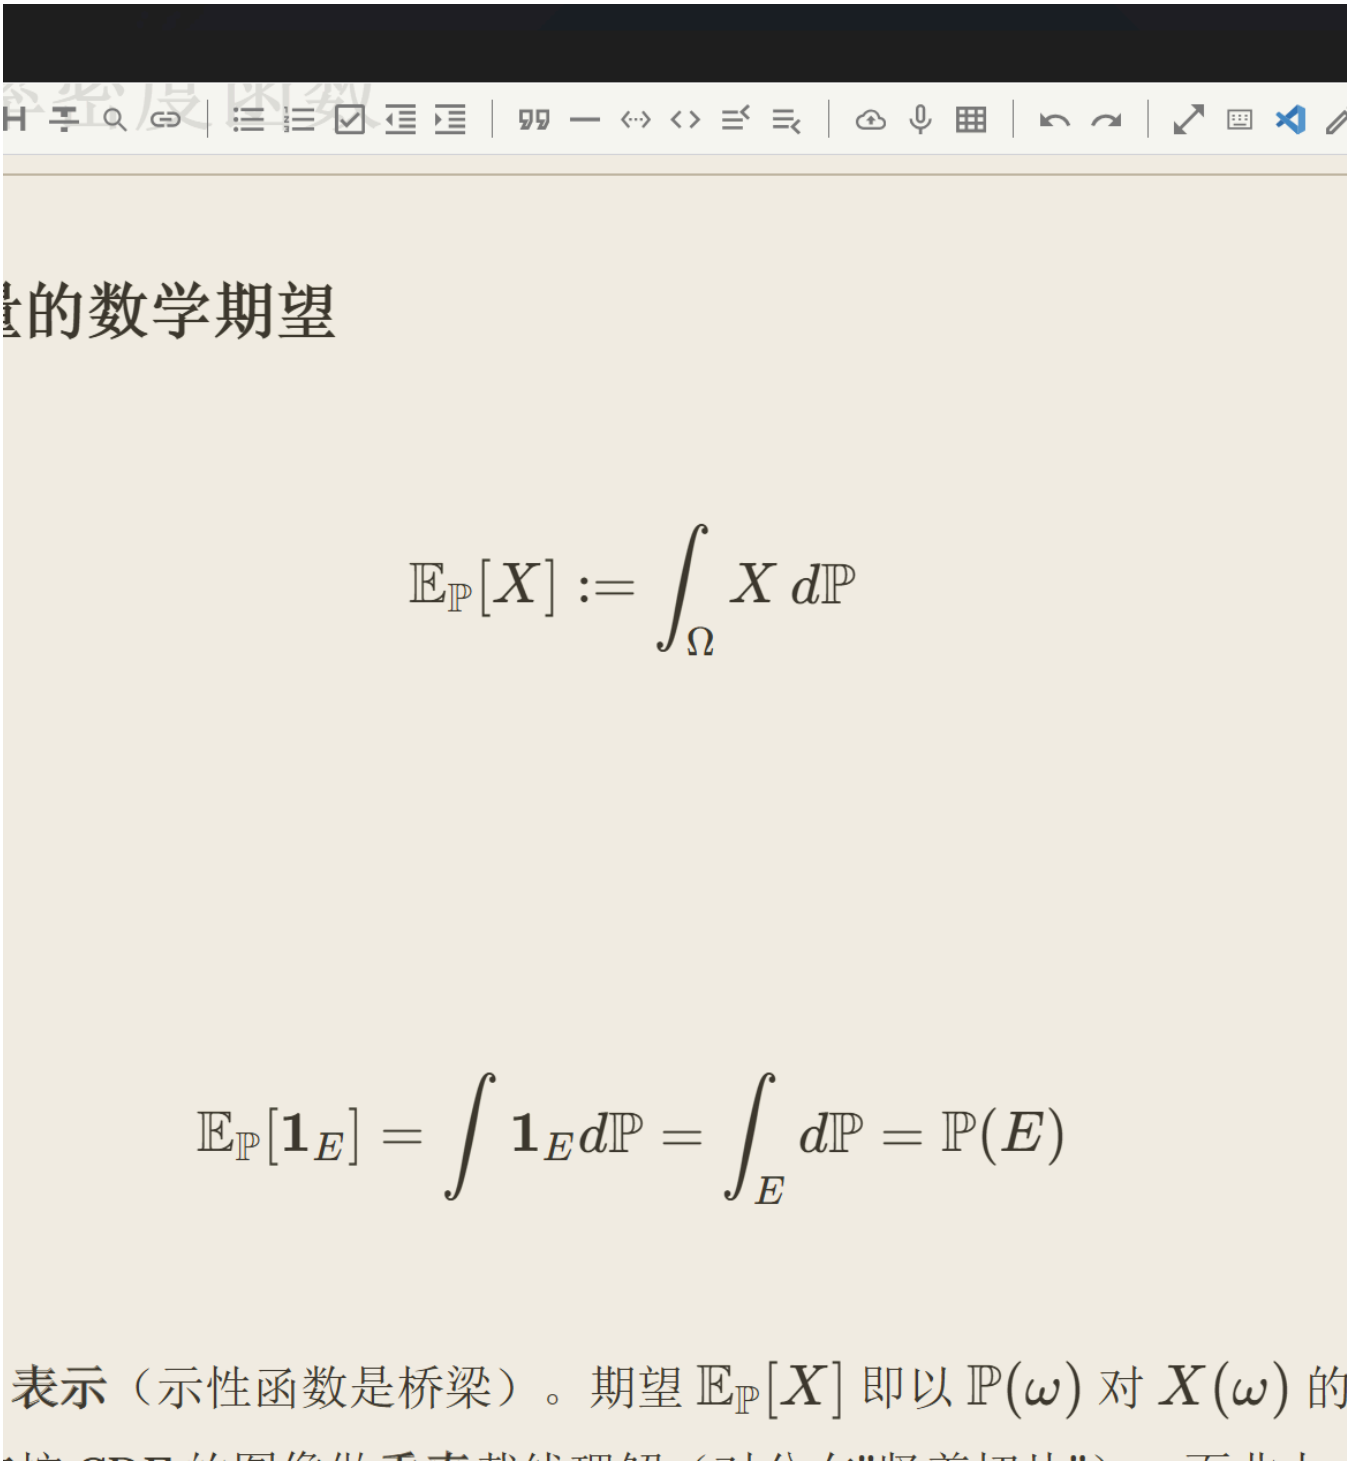
(2) 共性：两者均以"**单一函数值 × 自变量小区间（测度） = 小矩形面积**"来逼近积分收敛值。

下图上半为 Riemann （竖切），下半为 Lebesgue （横切，按函数值分堆）：

[图片未能嵌入：Riemann 与 Lebesgue 积分对比]

（若外链图失效，文字版： Riemann 把定义域切成竖条、每条取一个代表值； Lebesgue 把值域切成横条、每一横条对应的定义域子集可以不连通——"按函数值分堆称重"。）

理解：这个区别就是概率论必须用勒贝格积分的原因——概率的"称重对象"本来就是事件（定义域的子集），而不是"自变量区间"。$\mathbb{E}[X] = \int X \, d\mathbb{P}$ 天生是 Lebesgue 式的。



1.4 期望与概率密度函数

1.4.1 Def 随机变量的数学期望

$$\mathbb{E}_{\mathbb{P}}[X] := \int_{\Omega} X \, d\mathbb{P}$$

理解：取 $X := \mathbf{1}_E$，则

$$\mathbb{E}_{\mathbb{P}}[\mathbf{1}_E] = \int \mathbf{1}_E d\mathbb{P} = \int_E d\mathbb{P} = \mathbb{P}(E)$$

——**测度可由积分定义、表示**（示性函数是桥梁）。期望 $\mathbb{E}_{\mathbb{P}}[X]$ 即以 $\mathbb{P}(\omega)$ 对 $X(\omega)$ 的不同取值按概率进行加权平均；从图像上应按 CDF 的图像做**垂直**截线理解（对分布"竖着切片"），而非上一节图中的水平截线。

1.4.2 Prop 概率密度函数与 RN 导数

考察由 X 诱导的概率测度 $\mathbb{P}_X$：由于测度可由积分表示，$\mathbb{P}_X(B) \equiv \int_B \mathbf{1}(x)\, d\mathbb{P}_X(x)$。相较于 $\mathbb{R}^k$ 上平凡的勒贝格测度 $\mathcal{L}(B) = \int_B \mathbf{1}(x)\, d\mathcal{L}(x)$，在非常不严格的意义上，

$$\mathbb{P}_X(B) = \int_B \mathbf{1}(x)\, d\mathbb{P}_X(x) = \int_B \mathbf{1}(x) \left(\frac{d\mathbb{P}_X(x)}{d\mathcal{L}(x)} \right) d\mathcal{L}(x)$$

即 $\mathbb{P}_X$ 对体积 $\mathcal{L}$ 进行了**伸缩变换**，而 $\frac{d\mathbb{P}_X(x)}{d\mathcal{L}(x)}$ 代表伸缩变换（测度变换）遵循的"密度"规律。

注意这种伸缩变换完全由 $\mathbb{P}_X$ 决定：既取决于随机变量 X 对底层事件的汇总方式，又取决于底层概率测度 $\mathbb{P}$。在测度 $\mathbb{P}$ 不变的情况下，可通过 $\frac{d\mathbb{P}_X(x)}{d\mathcal{L}(x)}$ 研究 X 的汇总（映射）方式的性质。

而由 $\mathbb{P}_X(\cdot)$ 与 $F_X(x)$ 一一对应，在符号形式上：

$$\frac{dF_X(x)}{dx} = \frac{d\mathbb{P}_X(x)}{d\mathcal{L}(x)}$$

可见**概率密度正是观测样本空间 $(\mathbb{R}^k, \mathcal{B})$ 上，诱导概率测度 $\mathbb{P}_X$ 对平凡勒贝格测度 $\mathcal{L}$ 的 Radon–Nikodym 导数。**

（记住这个视角。第 11 章会把"密度 = 测度间的导数"从直觉升格为定理，测度变换的全部技术都从它出发；终章 Heston 里 Girsanov 换测度时用的指数密度，就是它在路径空间上的直接后裔。）

本章对照 Øksendal

本书	Øksendal 5th ed.
§1.1–1.2 可测空间、随机变量、诱导测度	Ch.2 §2.1（更紧凑，无原子/三层理解铺垫）
§1.3 勒贝格积分、控制收敛	（默认已知；正文随用随引）
§1.4 期望、密度 = RN 导数伏笔	Ch.2 §2.1 + 附录 A（正态分布性质）

本书多给的：随机变量三层理解、密度即 RN 导数的伏笔、Riemann/Lebesgue 的图解对照。Øksendal 更严格的：测度论细节（它同样略过，但给出了引用）。

下一章钩子

现在你手里有了"随机变量"和"期望"。但定价的核心动作是：**在只掌握部分信息时，给出最优预测。**这就要求把"部分信息"（一个子 σ-代数 $\mathcal{G}$）变成期望的"条件"。关键困难是：$\mathcal{G}$ 若是无限精细的（连续型），"已知 $\mathcal{G}$"无法用"某个事件发生"来描述，条件期望必须靠**抽象定义**硬造出来——而理解它的钥匙，是把 σ-代数想成一堆"原子"拼成的马赛克。